

ベイズ統計 教科書

- テーマ: ベイズ統計
- 対象読者: 理工系大学生・初学者
- レベル: 初～中級
- 想定学習時間: 40～60時間
- 前提知識: 高校数学（確率・微分・積分）。微積分の計算が読みこなせれば十分

目次

- はじめに
- この本の使い方
- 頻度論とベイズ統計
- 歴史の一瞥
- 第1章 確率の基礎
- 学習目標
- 1.1 確率とは何か
- 1.2 条件付き確率
- 1.3 乗法定理と全確率の定理
- 1.4 独立性
- 本章のまとめ
- 練習問題
- 第2章 ベイズの定理とベイズ更新
- 学習目標
- 2.1 ベイズの定理の導出
- 2.2 診断テストの例
- 2.3 事後確率と逐次更新
- 2.4 事前確率の役割
- 本章のまとめ
- 練習問題
- 第3章 事前分布と尤度
- 学習目標
- 3.1 尤度関数
- 3.2 事前分布の種類
- 3.3 事後分布の計算
- 3.4 共役事前分布
- 本章のまとめ
- 練習問題
- 第4章 ベルヌーイ・二項分布モデル

- 学習目標
- 4.1 ベルヌーイ分布と二項分布
- 4.2 ベータ分布
- 4.3 共役更新（ベータ・二項モデル）
- 4.4 MAP推定と事後平均
- 4.5 次の試行の予測
- 本章のまとめ
- 練習問題
- 第5章 正規分布モデル
- 学習目標
- 5.1 正規分布の復習
- 5.2 平均未知・分散既知の場合（正規－正規モデル）
- 5.3 事後予測分布
- 5.4 分散未知の場合（逆ガンマ分布）
- 5.5 正規－逆ガンマモデル
- 本章のまとめ
- 練習問題
- 第6章 ポアソン分布モデル
- 学習目標
- 6.1 ポアソン分布
- 6.2 ガンマ分布
- 6.3 共役更新（ポアソン－ガンマモデル）
- 6.4 応用例
- 本章のまとめ
- 練習問題
- 第7章 点推定・区間推定と信用区間
- 学習目標
- 7.1 ベイズ推定量
- 7.2 信用区間と HPD 区間
- 7.3 頻度論の信頼区間との違い
- 7.4 例による比較
- 本章のまとめ
- 練習問題
- 第8章 モデル選択とベイズ因子
- 学習目標
- 8.1 周辺尤度
- 8.2 事前予測分布
- 8.3 ベイズ因子
- 8.4 AIC・BICとの関係
- 本章のまとめ
- 練習問題

- 第9章 多腕バンディットと意思決定
- 学習目標
- 9.1 探索と活用のトレードオフ
- 9.2 Thompson sampling
- 9.3 UCB と ϵ -greedy
- 9.4 A/B テストとベイズの判断
- 9.5 ベイズ最適化の考え方
- 本章のまとめ
- 練習問題
- 第10章 MCMC入門と実践
- 学習目標
- 10.1 なぜ MCMC が必要か
- 10.2 マルコフ連鎖
- 10.3 メトロポリス＝ヘイスティングス法
- 10.4 ギブスサンプリング
- 10.5 収束診断
- 10.6 Python / PyMC での実践
- 10.7 総まとめ
- 本章のまとめ
- 練習問題
- 付録A 練習問題の解答
- 第1章
- 第2章
- 第3章
- 第4章
- 第5章
- 第6章
- 第7章
- 第8章
- 第9章
- 第10章
- 付録B 用語集
- 付録C 記号表
- 資格対応（統計検定）

はじめに

この本の使い方

本書は、ベイズ統計をゼロから体系的に学ぶための教科書です。理工系大学生の初～中級レベルの内容を想定し、高校数学（特に確率と微積分）を前提として、条件付き確率から MCMC（マルコフ連鎖モンテ

カルロ) 法までを無理なく読める順序で並べています。

各章は次の流れで構成されています。

- 1. 学習目標 — その章で身につけること
- 2. 本文 — 概念の説明と数値例
- 3. 本章のまとめ — 要点の整理
- 4. 練習問題 — 3～5問（解答は付録A）

計算には Python のコード例も一部入れていますが、手計算で追える数値例を中心にしているので、コードが読めなくても学習を進められます。

頻度論とベイズ統計

統計学には大きく分けて二つの流れがあります。

- 頻度論 (古典的統計学) : 「確率」とは、多数回の試行を繰り返したときの相対頻度であると考え
る。母平均 μ などの「真の値」は固定された定数で、それをデータから推定する。
- ベイズ統計: 確率を不確実性の度合いとして捉える。「母平均 μ が 3 である確率」のような言い方が
許される。未知のパラメータは確率変数として扱い、データが得られるたびにその信念 (確率分布)
を更新していく。

観点	頻度論	ベイズ統計
確率の解釈	長期的な相対頻度	信念・不確実性の度合い
パラメータ	固定された未知定数	確率変数 (分布を持つ)
推定の出力	点推定値 + 信頼区間	事後分布 (点推定値 + 信用区間)
事前情報	原則使わない	事前分布として明示的に使う
判断材料	p 値・有意水準	事後確率・ベイズ因子

ベイズ統計の最大の特徴は、「データが得られたら信念を更新する」という枠組みが**逐次的**であること、そして不確実性を「確率分布」という形で直接扱えることです。

歴史の一瞥

ベイズ統計の名前は、18世紀のイギリスの牧師 トーマス・ベイズ (1702年頃～1761年) に由来します。彼の遺稿『An Essay towards Solving a Problem in the Doctrine of Chances』(1763年) には、逆確率 (現在のベイズの定理) の考え方が含まれていました。その後、フランスの数学者 ピエール＝シモン・ラプラス (1749～1827) がこれを独立に発展させ、天体力学の誤差論などに応用しました。

しかし、19世紀以降、頻度論が統計学の主流となり、ベイズ統計は長く傍流扱いされていました。1970年代以降、計算機の性能向上により、厳密に計算が難しかった事後分布を近似する **MCMC** 法が実用化され、ベイズ統計は爆発的に普及しました。現在では機械学習、医療統計、マーケティング、スポーツ分析など幅広い分野で使われています。

現代ではベイズ統計は「特殊な手法」ではなく、統計学の標準的な位置づけになりつつあります。2026年1月には、米国FDA（アメリカ食品医薬品局）が医薬品・生物製剤の臨床試験におけるベイズ統計の利用に関するドラフトガイダンス（草案）を公表しました。また、統計検定準1級（日本統計学会認定）の出題範囲にも「ベイズ法」が正式に含まれています。本書の内容は、こうした実務・資格試験の入口としても役立ちます。

第1章 確率の基礎

学習目標

- 確率の公理的定義と基本的な性質を理解する。
- 条件付き確率の意味を正確に理解し、計算できる。
- 乗法定理と全確率の定理を使いこなせる。
- 独立事象と排反事象の区別ができる。

1.1 確率とは何か

確率を数学的に扱うには、**事象**と**標本空間**を定義します。さいころを1回振る実験を考えましょう。起こりうる結果の集合

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

を**標本空間**と呼びます。標本空間の部分集合（たとえば「偶数が出る」 $= \{2, 4, 6\}$ ）を**事象**と呼びます。

確率 $P(A)$ は次の3つの公理を満たす量として定義されます。

- 任意の事象 A について $0 \leq P(A) \leq 1$
- 標本空間全体について $P(\Omega) = 1$
- 互いに排反な事象列 $A_1, A_2, \dots$ について、 $P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$

排反とは、二つの事象が同時に起こらないことをいいます（ $A \cap B = \emptyset$ ）。

さいころのように各結果が等確率で起こる場合、事象 A の確率は

$$P(A) = |A| / |\Omega|$$

と計算できます。ここで $|A|$ は A に含まれる結果の個数です。「偶数が出る」なら $|A| = 3$, $|\Omega| = 6$ で $P(A) = 3/6 = 1/2$ です。

1.2 条件付き確率

「ある情報 B が得られたときに、事象 A が起こる確率」を**条件付き確率**と呼び、 $P(A | B)$ と書きます。定義は

$$P(A | B) = P(A \cap B) / P(B) \quad (\text{ただし } P(B) > 0)$$

です。「B という条件下」で考えるとは、起こりうる世界を B に絞り込み、その中で A が起こる割合を見ることを意味します。

例 1.1 クラスに30人の学生がいて、うち18人が理系、12人が文系です。理系のうち6人が「統計学が好き」、文系のうち3人が「統計学が好き」だとします。学生を無作為に1人選んだとき、「理系である」事象を B、「統計学が好き」事象を A とします。

- $P(B) = 18/30 = 3/5$
- $P(A \cap B) = 6/30 = 1/5$
- よって $P(A | B) = (1/5) / (3/5) = 1/3$

理系の中だけで見ると、統計学が好きな割合は $6/18 = 1/3$ であり、定義と一致しています。

1.3 乗法定理と全確率の定理

条件付き確率の定義を変形すると、乗法定理が得られます。

$$P(A \cap B) = P(A | B) P(B) = P(B | A) P(A)$$

次に、標本空間が排反な部分に分割されている状況を考えます。事象 $B_1, B_2, \dots, B_n$ が互いに排反で、その和集合が Ω 全体であるとき（これを分割と呼ぶ）、全確率の定理が成り立ちます。

$$P(A) = P(A | B_1)P(B_1) + P(A | B_2)P(B_2) + \dots + P(A | B_n)P(B_n)$$

例 1.2 ある工場では、部品を機械 M_1 で60%、機械 M_2 で40%生産しています。 M_1 の不良率は2%、 M_2 の不良率は5%だとします。製品を1つ選んだとき不良品である確率は、全確率の定理より

$$P(\text{不良}) = 0.02 \times 0.6 + 0.05 \times 0.4 = 0.012 + 0.020 = 0.032$$

となります。

1.4 独立性

事象 A と B が独立であるとは、

$$P(A \cap B) = P(A) P(B)$$

が成り立つことをいいます。これは $P(A | B) = P(A)$ と同値であり、「B を知っても A の確率は変わらない」という意味です。

注意: 独立と排反は別物です。排反 ($A \cap B = \emptyset$) なら、 $P(A \cap B) = 0$ なので、互いに正の確率を持つ排反事象は独立ではありません。さいころで「1が出る」と「2が出る」は排反ですが独立ではありません（1が出たと分かれば2が出た可能性は0になるからです）。

本章のまとめ

- 確率は3つの公理で定義される。

- 条件付き確率 $P(A | B) = P(A \cap B) / P(B)$ は「B に絞った世界での A の割合」。
- 乗法定理 $P(A \cap B) = P(A | B)P(B)$ 。
- 全確率の定理で、原因ごとに場合分けして確率を計算できる。
- 独立事象は $P(A \cap B) = P(A)P(B)$ 。排反とは別概念。

練習問題

練習問題 1.1 袋の中に赤玉4個、白玉6個が入っている。無作為に1個取り出したところ赤玉だった。次の白玉を引く確率を条件付き確率の考え方で求めなさい（玉は戻さない）。

練習問題 1.2 ある疾患の有病率は1%である。検査は感度（実際に病気の人を陽性と判定する確率）が95%、特異度（病気でない人を陰性と判定する確率）が90%である。無作為に選んだ人が陽性と判定されたとき、実際に病気である確率を求めなさい（この問題は第2章で扱うベイズの定理の準備です）。

練習問題 1.3 AさんとBさんがゲームをする。Aさんが勝つ確率は3/5である。ただし、Bさんが先手のときはAさんが勝つ確率が1/2になり、Aさんが先手のときは3/4になる。先手は等確率で決まるものとする。Aさんが勝つ確率を全確率の定理で求めなさい。

練習問題 1.4 さいころを2回振るとき、「1回目が偶数」と「2回目が6」は独立か？理由をつけて答えなさい。

第2章 ベイズの定理とベイズ更新

学習目標

- ベイズの定理を導出できる。
- 原因が複数の場合の事後確率を計算できる。
- 逐次更新（ベイズ更新）の考え方を理解する。

2.1 ベイズの定理の導出

乗法定理から出発します。

$$P(A \cap B) = P(A | B) P(B) = P(B | A) P(A)$$

両辺を $P(B)$ で割ると、

$$P(A | B) = P(B | A) P(A) / P(B)$$

これがベイズの定理です。ここで分母は全確率の定理を使って計算できます。

より一般的な形として、原因が $B_1, \dots, B_n$ の場合を考えます。

$$P(B_i | A) = P(A | B_i)P(B_i) / \sum_j P(A | B_j)P(B_j)$$

ベイズ統計では、この式を次のように読み替えます。

- $P(B_i)$: 事前確率 — データを見る前の信念
- $P(A | B_i)$: 尤度 — そのパラメータのもとでデータが得られる確率
- $P(B_i | A)$: 事後確率 — データを見た後の信念

2.2 診断テストの例

第1章の練習問題 1.2 をベイズの定理で解きます。病気の有無を D (病気) + と D^- で表し、検査陽性を $T+$ とします。

- 事前確率: $P(D+) = 0.01$, $P(D^-) = 0.99$
- 感度: $P(T+ | D+) = 0.95$
- 特異度: $P(T^- | D^-) = 0.90$ 、つまり $P(T+ | D^-) = 0.10$

求めるのは $P(D+ | T+)$ です。

$$P(D+ | T+) = P(T+ | D+)P(D+) / [P(T+ | D+)P(D+) + P(T+ | D^-)P(D^-)]$$

$$= (0.95 \times 0.01) / (0.95 \times 0.01 + 0.10 \times 0.99)$$

$$= 0.0095 / (0.0095 + 0.099) = 0.0095 / 0.1085 \approx 0.0876$$

つまり約 **8.8%** です。感度が95%と高い検査でも、有病率が1%だと陽性と判定された人の約9割は実は病気ではないことになります。これが「陽性でもパニックになるな」と言われる理由です。この結果は事前確率（有病率）に強く依存している点が重要です。

2.3 事後確率と逐次更新

ベイズ統計の特徴は、同じ公式を何度も適用して信念を更新できることです。前節の例で、病気の有無の事前確率を更新したとしましょう。最初の検査で陽性だった後、もう一度独立に同じ検査を行い、また陽性になったとします。

2回目では、1回目の事後確率 0.0876 を新しい事前確率として使います。

$$P(D+ | T+, T+) = (0.95 \times 0.0876) / (0.95 \times 0.0876 + 0.10 \times 0.9124)$$

$$\text{分子} = 0.0832, \text{分母} = 0.0832 + 0.0912 = 0.1744$$

$$P \approx 0.0832 / 0.1744 \approx 0.477$$

2回続けて陽性なら病気である確率は約 **48%** に上がります。さらに3回目も陽性なら約 90% に達します。このように、新しいデータを得るたびに「前の事後分布を次の事前分布にする」操作を**逐次更新**または**ベイズ更新**と呼びます。

2.4 事前確率の役割

ベイズの定理の結果は事前確率に依存します。事前確率が非常に小さい場合、検査の感度が高くても事後確率は大きく上がりません。逆に事前確率が高い場合、陽性が続けば事後確率はすぐ1に近づきます。

この「事前の情報が結果に影響する」ことが、頻度論とベイズ統計を分ける大きな違いです。ベイズ統計は、事前分布をどう選ぶかが常に議論になります（第3章）。

本章のまとめ

- ベイズの定理: $P(A | B) = P(B | A)P(A) / P(B)$ 。
- 事前確率 $\times$ 尤度 $\propto$ 事後確率。
- 有病率が低いと、感度の高い検査でも陽性的中率は低い。
- 事後確率を次の事前確率として使い、データを得るたびに更新するのがベイズ更新。

練習問題

練習問題 2.1 ある工場の製品の不良率は5%である。不良品かどうかを判定する検査は、不良品を正しく不良と判定する確率が98%、良品を誤って不良と判定する確率が4%である。検査で「不良」と判定された製品が実際に不良品である確率を求めなさい。

練習問題 2.2 コインがある。表が出る確率 θ は 0.4 か 0.6 のどちらかであることが分かっている。事前には $\theta = 0.4$ と $\theta = 0.6$ は等確率とする。このコインを5回振って表が3回出た。事後確率 $P(\theta = 0.6 | \text{データ})$ を求めなさい。

練習問題 2.3 練習問題 2.2 の状況で、さらに同じコインを5回振って表が4回出た。ベイズ更新を適用して $P(\theta = 0.6 | \text{全データ})$ を求めなさい。

練習問題 2.4 「3回続けて陽性で病気の確率が約90%になる」ことを、本文の数値（有病率1%、感度95%、特異度90%）で確認しなさい。

第3章 事前分布と尤度

学習目標

- 尤度関数の意味を理解する。
- 事前分布の種類（無情報・弱情報）と選び方を理解する。
- 事後分布が「事前分布 $\times$ 尤度」の比例定数までで計算できることを理解する。

3.1 尤度関数

パラメータ θ をもつ確率分布からデータ $x_1, \dots, x_n$ が得られたとします。データの同時分布を、 θ の関数として見たものを尤度関数といいます。

$$L(\theta) = f(x_1, \dots, x_n | \theta)$$

尤度は「 θ が与えられたときに、このデータが得られる確率（確率密度）」を表します。 θ が尤もらしいほど $L(\theta)$ は大きくなります。最尤推定は、 $L(\theta)$ を最大にする θ を推定値とする方法です。

注意: ベイズ統計では $L(\theta)$ を「 θ の関数」として扱い、全 θ にわたって積分しても1になる必要はありません (確率分布ではない)。計算の都合上、定数倍を無視できることが多いです。

例 3.1 コインを3回振って「表・表・裏」が出たとします。表の出る確率を θ とすると、各回は独立なので、

$$L(\theta) = \theta \times \theta \times (1 - \theta) = \theta^2(1 - \theta)$$

これを最大にする θ を求めると、微分して $dL/d\theta = 2\theta(1 - \theta) - \theta^2 = \theta(2 - 3\theta) = 0$ より $\theta = 2/3$ です。直感 (3回中2回表) と一致します。

3.2 事前分布の種類

事後分布 = 事前分布 $\times$ 尤度 (比例定数を除く) なので、事前分布の選び方が重要です。

- **無情報事前分布:** 「何も知らない」状態を表す分布。たとえば $\theta \in [0,1]$ なら一様分布 $U(0,1)$ を使う。ジェフリーズ事前分布などもある。
- **弱情報事前分布:** あまり強くない事前情報を与える分布。たとえば「 θ は0.5付近だろう」という緩い知識を幅広い分布で表現する。
- **情報を多く含む事前分布:** 過去のデータや専門家の知識を反映した分布。事前分布が強すぎるとデータが少ないうちは事後分布が事前分布に引っ張られる。

事前分布は「データが十分にあれば事後分布への影響は小さくなる」という性質を持ちます。n が大きくなると、事後分布は尤度に支配され、事前分布の影響は薄れます。

3.3 事後分布の計算

パラメータ θ が連続の場合、ベイズの定理の積分版は

$$p(\theta | x) = p(x | \theta) p(\theta) / \int p(x | \theta) p(\theta) d\theta$$

です。分母の積分 $\int p(x | \theta) p(\theta) d\theta$ は周辺尤度 (正規化定数) と呼ばれ、 θ を含みません。したがって、

$$p(\theta | x) \propto p(x | \theta) p(\theta)$$

と書けます。比例定数は、積分して1になるように後で決めることができます。この「 $\propto$ 」の形で扱えるのが、ベイズ計算の大きな武器です。

例 3.2 $\theta \in [0,1]$ 、事前分布は一様分布 $p(\theta) = 1$ 、データはベルヌーイ試行で「表・表・裏」とする。

$$p(\theta | x) \propto \theta^2(1 - \theta) \times 1 = \theta^2(1 - \theta)$$

これはベータ分布 $\text{Beta}(3, 2)$ の形 (第4章) であり、正規化すると

$$p(\theta | x) = 12 \theta^2(1 - \theta)$$

となります ($\int_0^1 12 \theta^2(1 - \theta) d\theta = 1$ を確認できます)。

3.4 共役事前分布

計算を便利にするため、共役事前分布という概念が重要です。

事後分布が事前分布と同じ分布族になるような事前分布を共役事前分布と呼ぶ。

たとえばベルヌーイ分布のパラメータ θ にベータ分布 $\text{Beta}(\alpha, \beta)$ を事前分布として与えると、事後分布もベータ分布 $\text{Beta}(\alpha + \text{表の数}, \beta + \text{裏の数})$ になります。共役事前分布を使えば、事後分布を手計算で求めることができ、パラメータの更新が単純な足し算になります。

代表的な共役関係は第4章から第6章で詳しく扱います。

尤度	共役事前分布	事後分布
ベルヌーイ・二項	ベータ分布	ベータ分布
正規（平均未知・分散既知）	正規分布	正規分布
正規（分散未知）	逆ガンマ分布	逆ガンマ分布
ポアソン	ガンマ分布	ガンマ分布

本章のまとめ

- 尤度関数 $L(\theta)$ は、 θ の関数として見たデータの確率。
- 事後分布 $\propto$ 事前分布 $\times$ 尤度。正規化定数は後から決められる。
- 事前分布には無情報・弱情報・情報量の多いものがある。
- 共役事前分布を使うと事後分布が同族で閉じ、手計算できる。

練習問題

練習問題 3.1 コインの表が出る確率 θ の事前分布を一様分布 $U(0,1)$ とする。4回投げて「表、表、裏、表」が出た。事後分布 $p(\theta | x)$ の形（正規化定数を除く）を書きなさい。

練習問題 3.2 練習問題 3.1 の事後分布の正規化定数を求め、 $p(\theta | x)$ を確定させなさい。

練習問題 3.3 事前分布に $\text{Beta}(10, 10)$ を使った場合と一様分布（ $= \text{Beta}(1,1)$ ）を使った場合で、練習問題 3.1 のデータに対する事後分布の形はどう異なるか説明しなさい。

練習問題 3.4 最尤推定とベイズ推定の違いを、事前分布の役割に注目して説明しなさい。

第4章 ベルヌーイ・二項分布モデル

学習目標

- ベルヌーイ分布と二項分布を復習し、その関係を理解する。
- ベータ分布の性質（期待値・分散）を理解する。

- ベータ・二項モデルの共役更新を手計算できる。
- MAP推定と事後平均を計算できる。

4.1 ベルヌーイ分布と二項分布

コイン投げのように、結果が「成功」「失敗」の2つしかない試行をベルヌーイ試行といいます。表が出る確率を θ とすると、確率変数 $X \in \{0, 1\}$ の分布は

$$P(X = x) = \theta^x (1 - \theta)^{1-x} \quad (x = 0, 1)$$

であり、期待値 $E[X] = \theta$ 、分散 $\text{Var}(X) = \theta(1 - \theta)$ です。

独立なベルヌーイ試行を n 回行い、成功回数を Y とすると、 Y は二項分布 $\text{Binomial}(n, \theta)$ に従います。

$$P(Y = k) = C(n, k) \theta^k (1 - \theta)^{n-k} \quad (k = 0, 1, \dots, n)$$

ここで $C(n, k) = n! / (k!(n - k)!)$ は二項係数です。期待値は $n\theta$ 、分散は $n\theta(1 - \theta)$ です。

4.2 ベータ分布

区間 $[0, 1]$ 上の連続分布で、二つの正のパラメータ α, β をもつ分布がベータ分布 $\text{Beta}(\alpha, \beta)$ です。確率密度関数は

$$f(\theta) = \theta^{(\alpha-1)} (1 - \theta)^{(\beta-1)} / B(\alpha, \beta) \quad (0 \leq \theta \leq 1)$$

です。ここで $B(\alpha, \beta)$ はベータ関数で、正規化定数です。

$$B(\alpha, \beta) = \int_0^1 \theta^{(\alpha-1)} (1 - \theta)^{(\beta-1)} d\theta = \Gamma(\alpha) \Gamma(\beta) / \Gamma(\alpha + \beta)$$

Γ はガンマ関数（第6章で詳述）です。期待値と分散は

$$E[\theta] = \alpha / (\alpha + \beta) \quad \text{Var}(\theta) = \alpha \beta / ((\alpha + \beta)^2 (\alpha + \beta + 1))$$

です。

- $\text{Beta}(1, 1)$ は一様分布 $U(0,1)$ 。
- $\text{Beta}(\alpha, \beta)$ の形状は α, β が1より大きいとピークを持つベル型。

例 4.1 $\text{Beta}(3, 2)$ の期待値は $3/5 = 0.6$ 、分散は $(3 \times 2) / ((5)^2 (6)) = 6/150 = 1/25$ です。

4.3 共役更新（ベータ・二項モデル）

表の出る確率 θ の事前分布を $\text{Beta}(\alpha, \beta)$ とします。データとして n 回の投擲で表が k 回出たとします。尤度は二項分布

$$L(\theta) \propto \theta^k (1 - \theta)^{n-k}$$

です。事後分布は

$$p(\theta | k) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1} \times \theta^k(1-\theta)^{n-k} = \theta^{\alpha+k-1}(1-\theta)^{\beta+n-k-1}$$

となり、これは $\text{Beta}(\alpha + k, \beta + n - k)$ です。つまり事前分布のパラメータに「表の数」と「裏の数」を足すだけで事後分布が求まります。

例 4.2 事前分布を $\text{Beta}(2, 2)$ (θ は0.5付近、緩い情報) とする。コインを10回投げて表が7回出た。

- 事後分布は $\text{Beta}(2 + 7, 2 + 3) = \text{Beta}(9, 5)$
- 事後平均 $= 9/14 \approx 0.643$
- 事後 MAP (最頻値) $= (9 - 1)/(9 + 5 - 2) = 8/12 \approx 0.667$

データの成功割合 0.7 に近い値になっていますが、事前分布の影響で少し0.5側に引っ張られています。

4.4 MAP推定と事後平均

事後分布から「代表値」を取り出す代表的な方法が二つあります。

- 事後平均 $E[\theta | \text{data}] = (\alpha + k) / (\alpha + \beta + n)$
- MAP推定値 (事後分布の最頻値) $= (\alpha + k - 1) / (\alpha + \beta + n - 2)$ ($\alpha + k > 1, \beta + n - k > 1$ のとき)

事後平均は、予測や損失最小化の文脈でよく使われます (第7章)。MAPは最尤推定に事前分布を足したようなもので、正則化の働きを持ちます。n が大きいと両者はデータの成功割合 k/n に近づきます。

4.5 次の試行の予測

「次に表が出る確率」を事後予測確率といいます。 θ が事後分布 $\text{Beta}(\alpha + k, \beta + n - k)$ に従うとき、次回表が出る確率は

$$P(\text{次が表}) = E[\theta] = (\alpha + k) / (\alpha + \beta + n)$$

となります。これは「今までの成功数 + 事前の成功数分」を「総試行数 + 事前の試行数分」で割ったものです。例4.2 では $9/14 \approx 0.643$ です。

本章のまとめ

- ベルヌーイ試行の成功回数は二項分布に従う。
- $\text{Beta}(\alpha, \beta)$ は $\theta \in [0,1]$ の共役事前分布。
- ベータ・二項モデルの事後分布は $\text{Beta}(\alpha + k, \beta + n - k)$ とシンプル。
- 事後平均・MAPはデータが増えると k/n に収束する。
- 次の試行の予測確率は事後平均で与えられる。

練習問題

練習問題 4.1 事前分布 $\text{Beta}(3, 3)$ のもとで、コインを20回投げて表が12回出た。事後分布を求め、事後平均とMAP推定値を計算しなさい。

練習問題 4.2 事前分布を $\text{Beta}(1, 1)$ (一様分布) としたとき、表が k 回、裏が $n - k$ 回出た場合の事後平均が k/n よりもどのように異なるか、例を挙げて説明しなさい。

練習問題 4.3 前回までに表8回・裏2回が出ている。事前分布を $\text{Beta}(2, 2)$ としたとき、次に表が出る確率 (事後予測確率) を求めなさい。

練習問題 4.4 $\text{Beta}(10, 2)$ の期待値・分散・最頻値を求めなさい。

第5章 正規分布モデル

学習目標

- 正規分布の性質とパラメータの意味を復習する。
- 平均未知・分散既知のモデルで共役更新を実行できる。
- 事後予測分布の考え方を理解する。
- 平均未知・分散未知のモデル (正規-逆ガンマ) を理解する。

5.1 正規分布の復習

確率変数 X が正規分布 $N(\mu, \sigma^2)$ に従うとき、確率密度関数は

$$f(x) = (1 / \sqrt{2\pi\sigma^2}) \exp(-(x - \mu)^2 / (2\sigma^2))$$

です。期待値は μ 、分散は σ^2 です。 μ は分布の中心、 σ は広がり的大小を決めます。

実測値が正規分布に従う例は多く、測定誤差、身長、試験の点数などが代表的です。

5.2 平均未知・分散既知の場合 (正規-正規モデル)

分散 σ^2 は既知で、平均 μ だけが未知の場合を考えます。共役事前分布は正規分布です。

事前分布を $N(\mu_0, \tau_0^2)$ とします。データ $x_1, \dots, x_n$ が独立に $N(\mu, \sigma^2)$ から得られたとき、事後分布は正規分布になります。

$$\mu \mid x \sim N(\mu_1, \tau_1^2)$$

ここで

$$\tau_1^2 = 1 / (1/\tau_0^2 + n/\sigma^2) \quad \mu_1 = \tau_1^2 (\mu_0/\tau_0^2 + n\bar{x}/\sigma^2)$$

ただし $\bar{x} = (1/n) \sum x_i$ は標本平均です。

- 事後分散 τ_1^2 は「事前の精度 $1/\tau_0^2$ 」と「データの精度 n/σ^2 」の和の逆数。
- 事後平均 μ_1 は、事前平均と標本平均を精度で重み付けした平均。

例 5.1 ある工場で製造される鉄球の直径は正規分布に従い、分散 $\sigma^2 = 4$ (mm²) は既知とする。事前分布として $\mu \sim N(10, 9)$ (平均10mm、標準偏差3mm) を仮定する。5個の標本を測定し、標本平均 $\bar{x} = 11$ だった。

$n = 5$, $\sigma^2 = 4$ より、データの精度 $n/\sigma^2 = 5/4 = 1.25$ 、事前の精度 $1/\tau_0^2 = 1/9$ 。

$$\tau_1^2 = 1 / (1/9 + 5/4) = 1 / (0.1111 + 1.25) = 1/1.3611 \approx 0.7347 \rightarrow \tau_1 \approx 0.857$$

$$\mu_1 = 0.7347 \times (10/9 + 1.25 \times 11) = 0.7347 \times (1.1111 + 13.75) = 0.7347 \times 14.8611 \approx 10.92$$

事後分布は約 $N(10.92, 0.7347)$ 。標本平均11に近いですが、事前平均10の影響で10.92に寄っています。

5.3 事後予測分布

次のデータ X_{new} がどうなるかを予測する分布を事後予測分布といいます。

$$p(x_{\text{new}} | x) = \int p(x_{\text{new}} | \mu) p(\mu | x) d\mu$$

平均未知・分散既知の正規モデルでは、事後予測分布は

$$x_{\text{new}} \sim N(\mu_1, \sigma^2 + \tau_1^2)$$

となります。分散が $\sigma^2 + \tau_1^2$ になっている点に注意してください。パラメータ μ の不確実性 τ_1^2 が、データ自身の分散 σ^2 に加算されるため、個々のデータの予測は μ の推定よりも広がります。

例 5.2 例5.1 では、次の鉄球の直径の予測分布は $N(10.92, 4 + 0.7347) = N(10.92, 4.7347)$ です。標準偏差は約2.18mmです。

5.4 分散未知の場合（逆ガンマ分布）

現実には分散も未知の場合がほとんどです。 σ^2 の共役事前分布は逆ガンマ分布 Inv-Gamma(a, b) です。これは、ガンマ分布に従う変数の逆数が従う分布で、確率密度は

$$f(\sigma^2) = b^a / \Gamma(a) \times (\sigma^2)^{-(a+1)} \exp(-b/\sigma^2)$$

です。期待値は $b/(a - 1)$ ($a > 1$ のとき) です。

5.5 正規－逆ガンマモデル

平均 μ と分散 σ^2 の両方が未知の場合、共役事前分布は正規－逆ガンマ分布 NIG($\mu_0, \kappa_0, a_0, b_0$) です。データ n 個、標本平均 $\bar{x}$ 、標本偏差の2乗和 $S = \sum (x_i - \bar{x})^2$ が与えられたとき、事後分布は

$$\text{NIG}(\mu_1, \kappa_1, a_1, b_1)$$

となり、パラメータは次のように更新されます。

$$\kappa_1 = \kappa_0 + n \quad \mu_1 = (\kappa_0 \mu_0 + n \bar{x}) / \kappa_1 \quad a_1 = a_0 + n/2 \quad b_1 = b_0 + S/2 + (\kappa_0 n (\bar{x} - \mu_0)^2) / (2 \kappa_1)$$

事後予測分布はスチューデントのt分布になります。自由度 $\nu = 2a_1$ 、位置 μ_1 、尺度 $\sqrt{(b_1(\kappa_1+1))/(a_1 \kappa_1)}$ です。t分布は正規分布より裾が重く、分散の不確実性を反映します。

本章のまとめ

- 平均未知・分散既知の共役事前分布は正規分布。事後平均は精度で重み付けした平均。
- 事後予測分布の分散は $\sigma^2 + \tau_1^2$ と、パラメータの不確実性が加わる。
- 分散未知では逆ガンマ事前分布を使い、正規-逆ガンマモデルで両方更新する。
- 分散未知モデルの予測分布はt分布で、裾が正規分布より重い。

練習問題

練習問題 5.1 例5.1 の設定で、標本を $n = 20$ 個に増やし、標本平均が $\bar{x} = 10.5$ だった。事後分布 $N(\mu_1, \tau_1^2)$ を求め、 $n = 5$ のときと比較しなさい。

練習問題 5.2 平均未知・分散既知のモデルで、事前分布を非常に広い $N(0, 10^6)$ としたとき、事後平均はどのように簡略化されるか示しなさい。

練習問題 5.3 例5.2 で予測分布の標準偏差が、 μ の事後標準偏差よりも大きくなる理由を説明しなさい。

練習問題 5.4 正規-逆ガンマモデルの事後予測分布が t分布になることの直感的な理由を説明しなさい。

第6章 ポアソン分布モデル

学習目標

- ポアソン分布の意味と性質を理解する。
- ガンマ分布とその期待値・分散を理解する。
- ポアソン-ガンマモデルの共役更新を実行できる。
- カウントデータの実例（事故件数・到着数）に応用できる。

6.1 ポアソン分布

単位時間あたり平均 λ 回起こる事象の、単位時間中の発生回数 X が従う分布をポアソン分布 $\text{Poisson}(\lambda)$ といいます。

$$P(X = k) = \lambda^k e^{-\lambda} / k! \quad (k = 0, 1, 2, \dots)$$

期待値も分散も λ です。

ポアソン分布は、稀な事象のカウントに適しています。コールセンターに1時間に掛かってくる電話の数、交差点での年間事故件数、放射性崩壊の回数などが例です。二項分布で n が大きく p が小さいときの極限としても導かれます。

6.2 ガンマ分布

正のパラメータ a, b をもつ分布が**ガンマ分布** $\text{Gamma}(a, b)$ です。確率密度関数は

$$f(\lambda) = b^a / \Gamma(a) \times \lambda^{a-1} e^{-(b\lambda)} \quad (\lambda > 0)$$

です。ここで $\Gamma(a) = \int_0^\infty t^{a-1} e^{-t} dt$ は**ガンマ関数**です。期待値と分散は

$$E[\lambda] = a/b \quad \text{Var}(\lambda) = a/b^2$$

です。ガンマ分布は $\lambda > 0$ を支えとする分布で、ポアソン分布のパラメータ λ の共役事前分布です。

6.3 共役更新（ポアソン－ガンマモデル）

λ の事前分布を $\text{Gamma}(a, b)$ とします。データとして、 n 期間に観測された総発生回数を $T = x_1 + \dots + x_n$ とします。尤度は

$$L(\lambda) = \lambda^T e^{-(n\lambda)} / (x_1! \dots x_n!)$$

定数部を無視すると $L(\lambda) \propto \lambda^T e^{-(n\lambda)}$ です。事後分布は

$$p(\lambda | x) \propto \lambda^{a-1} e^{-(b\lambda)} \times \lambda^T e^{-(n\lambda)} = \lambda^{a+T-1} e^{-(b+n)\lambda}$$

となり、これは $\text{Gamma}(a + T, b + n)$ です。つまり「発生回数の総和」を a に、「観測期間数」を b に足すだけです。

例 6.1 ある交差点の月間事故件数の平均 λ を推定したい。事前分布として、 $\lambda \sim \text{Gamma}(2, 1)$ を用いる。10ヶ月のデータで総事故件数が 25 件だった。

- 事後分布は $\text{Gamma}(2 + 25, 1 + 10) = \text{Gamma}(27, 11)$
- 事後平均 = $27/11 \approx 2.45$ 件/月
- 事前平均は $2/1 = 2$ 件/月だったので、データ（月平均2.5件）に引っ張られて 2.45 に更新された。

6.4 応用例

コールセンター 1時間あたりの平均着信件数 λ を $\text{Gamma}(10, 2)$ で事前分布を設定（事前平均5件/時）。実測で5時間に 30 件の着信があったとします。

- 事後分布は $\text{Gamma}(10 + 30, 2 + 5) = \text{Gamma}(40, 7)$
- 事後平均 = $40/7 \approx 5.71$ 件/時

製造業の欠陥数 ある製品1個あたりの欠陥数を λ とする。事前分布 $\text{Gamma}(1, 1)$ （弱情報）。10個の製品を検査し、総欠陥数が 8 だった。

- 事後分布は $\text{Gamma}(1 + 8, 1 + 10) = \text{Gamma}(9, 11)$
- 事後平均 = $9/11 \approx 0.82$ 個/個

本章のまとめ

- ポアソン分布は稀な事象のカウントに使う。平均=分散= λ 。
- ガンマ分布 $\text{Gamma}(a, b)$ は λ の共役事前分布で、期待値 a/b 。
- 事後分布は $\text{Gamma}(a + T, b + n)$ 。更新は「総回数を a に、期間数を b に足す」。
- カウントデータの推定は、事前情報とデータを足し合わせるだけで行える。

練習問題

練習問題 6.1 事前分布 $\text{Gamma}(5, 2)$ の期待値と分散を求めなさい。

練習問題 6.2 ある機械の月間故障回数を λ とし、事前分布を $\text{Gamma}(1, 1)$ とする。12ヶ月のデータで総故障回数が 18 回だった。事後分布を求め、事後平均を計算しなさい。

練習問題 6.3 ポアソン分布の期待値と分散がどちらも λ であることを、定義式から確認しなさい（ヒント: 期待値は $E[X] = \sum k \lambda e^{-(\lambda)}/k!$ 、 $E[X^2] = \sum k^2 \lambda e^{-(\lambda)}/k!$ ）。

練習問題 6.4 練習問題 6.2 の設定で、さらに同じ機械を6ヶ月観測し、故障が8回発生した。逐次更新を使って新しい事後分布を求めなさい。

第7章 点推定・区間推定と信用区間

学習目標

- ベイズ推定量（事後平均・MAP・事後中央値）とその使い分けを理解する。
- 信用区間と HPD 区間を計算できる。
- 頻度論の信頼区間との解釈の違いを理解する。

7.1 ベイズ推定量

事後分布 $p(\theta | x)$ から代表値を取り出す方法には主に3つあります。

- 事後平均 $E[\theta | x] = \int \theta p(\theta | x) d\theta$ — 二乗損失を最小にする推定量。予測や報告に最もよく使う。
- MAP推定値 — 事後分布の最頻値。モード。もっとも「ありそうな」値。正則化の働き。
- 事後中央値 — 分布を2等分する値。絶対値損失を最小にする。ロバスト（外れ値に強い）。

ベータ・二項モデル $\text{Beta}(\alpha', \beta')$ ($\alpha' = \alpha + k$, $\beta' = \beta + n - k$) では、

- 事後平均 = $\alpha' / (\alpha' + \beta')$
- MAP = $(\alpha' - 1) / (\alpha' + \beta' - 2)$
- 事後中央値は数値的に求める必要があるが、 α' , β' が大きいと平均とほぼ同じ。

7.2 信用区間と HPD 区間

事後分布から「95%の確率で θ が入る区間」を95%信用区間 (credible interval) といいます。求め方は複数あります。

- 等裾信用区間 (equal-tailed interval) : 左裾2.5%、右裾2.5%を切り取った区間 $[q(0.025), q(0.975)]$ 。
- HPD区間 (Highest Posterior Density interval) : 事後密度が高い点から順に集めて確率質量95%になる区間。常に最短で、事後分布が単峰なら「密度が等しい2点で挟まれた区間」になります。

例 7.1 Beta(9, 5) (例4.2の事後分布) の95%信用区間を考えます。等裾区間は、ベータ分布の分位数関数 (統計ソフトや表で求める) を使い、約 $[0.39, 0.86]$ となります。事後平均0.643、区間幅約0.47です。

7.3 頻度論の信頼区間との違い

- 信用区間 (ベイズ) : 「 θ がこの区間に入る確率が95%」という直接的な解釈ができる。 θ は確率変数だから。
- 信頼区間 (頻度論) : 「この手順を繰り返したとき、真の θ を含む区間の割合が95%」という意味。 θ は固定値なので、特定の区間に「入る確率」という言い方はできない。

同じ言葉「95%」でも、確率変数が「区間」なのか「 θ 」なのかが逆転しているのが本質的な違いです。

7.4 例による比較

あるコインの表の出る確率 θ を、一様事前分布のもとで10回投げて表が8回出たデータで推定します。事後分布は Beta(9, 3)。

- 事後平均 $= 9/12 = 0.75$
- MAP $= 8/10 = 0.8$
- 95%等裾信用区間 $\approx [0.48, 0.94]$

頻度論の最尤推定は $\theta \simeq 0.8$ 、95%信頼区間 (正規近似) は約 $[0.55, 1.05]$ (上限が1を超える不自然な区間になることも)。ベイズの信用区間は $[0, 1]$ の範囲に収まっており、パラメータの定義域を自然に反映しています。

本章のまとめ

- 事後平均は二乗損失最小、MAPは最頻値、事後中央値はロバストな推定量。
- 信用区間は「 θ が入る確率95%」と直接解釈できる。
- HPD区間は等裾区間より短い。
- 頻度論の信頼区間は手順の性質に関する言明で、解釈が異なる。

練習問題

練習問題 7.1 Beta(30, 20) の事後平均とMAPを求めなさい。

練習問題 7.2 信用区間と信頼区間の解釈の違いを、それぞれの「確率変数」が何かを意識して説明しなさい。

練習問題 7.3 事後分布 $\text{Beta}(9, 3)$ の95%等裾信用区間の両端は何を表す量か、ベータ分布の分位数の意味に言及して説明しなさい。

練習問題 7.4 事後分布が二峰性（ピークが2つ）の場合、等裾区間とHPD区間はどちらがより適切か、理由とともに述べなさい。

第8章 モデル選択とベイズ因子

学習目標

- 周辺尤度と事前予測分布の意味を理解する。
- ベイズ因子を使って二つのモデルを比較できる。
- ベイズ因子と AIC・BIC の違いを理解する。

8.1 周辺尤度

ベイズの定理の分母

$$p(x) = \int p(x | \theta) p(\theta) d\theta$$

を周辺尤度（または証拠、evidence）と呼びます。これはデータの得られやすさを、事前分布で重み付けして平均した量です。事後分布の正規化定数でもあります。

二つのモデル M_1 と M_2 を比較するとき、データ x の周辺尤度 $p(x | M_1)$ と $p(x | M_2)$ の比がベイズ因子です。

8.2 事前予測分布

新しいデータ x_{new} の分布を、モデルと事前分布を通じて予測したもの

$$p(x_{\text{new}} | M) = \int p(x_{\text{new}} | \theta, M) p(\theta | M) d\theta$$

を事前予測分布といいます。これは「データを見る前に、このモデルがどんなデータを予想していたか」を表し、事後予測チェック（PPC）の事前版としてモデル検証にも使われます。周辺尤度は、実際のデータ x をこの分布で評価したものとも見なせます。

8.3 ベイズ因子

モデル M_1 対 M_2 のベイズ因子は

$$BF_{12} = p(x | M_1) / p(x | M_2)$$

です。事後オッズは事前オッズ $\times$ ベイズ因子で表されます。

$$P(M_1 | x) / P(M_2 | x) = BF_{12} \times P(M_1) / P(M_2)$$

$BF_{12} > 1$ ならデータは M_1 を支持しています。目安として、ジェフリーズの基準がよく使われます。

BF_{12}	解釈
1～3	ほぼ証拠なし
3～10	実質的な証拠
10～30	強い証拠
30～100	非常に強い証拠
>100	決定的な証拠

例 8.1 コインが「公平 ($M_0: \theta = 1/2$)」か「そうでない ($M_1: \theta$ は一様事前分布 $Beta(1,1)$)」かを比較します。10回投げて表が8回出たデータ x で考えます。

- M_0 の尤度: $p(x | M_0) = C(10, 8)(1/2)^{10} = 45/1024 \approx 0.0439$
- M_1 の周辺尤度: $p(x | M_1) = \int_0^1 C(10, 8) \theta^8 (1 - \theta)^2 d\theta = 45 \times B(9, 3) = 45 \times (8! 2! / 11!) = 45 \times (2/990) = 45/990 \approx 0.0455$

$B(9, 3) = \Gamma(9) \Gamma(3) / \Gamma(12) = (8! \times 2!) / 11! = 2 / (9 \times 10 \times 11) = 2/990$ より、 $p(x|M_1) = 45 \times 2/990 = 0.0909$ です。

- ベイズ因子 $BF_{10} = p(x|M_1)/p(x|M_0) = 0.0909/0.0439 \approx 2.07$

ジェフリーズの基準では「ほぼ証拠なし～実質的」。10回中8回の表でも、ベイズ的には「不公平」と断言する証拠は弱い、という結論になります。これは頻度論の p 値（約0.11）より慎重な判断です。

8.4 AIC・BICとの関係

頻度論のモデル選択指標として AIC と BIC があります。

- $AIC = -2 \log L(\theta) + 2k$ (k はパラメータ数) — 予測性能を重視。
- $BIC = -2 \log L(\theta) + k \log n$ — ベイズ因子のラプラス近似 (n が大きいとき) と密接に関係。より強いペナルティを課す。

BIC の差はおおむね $-2 \log BF_{12}$ に対応するため、「BIC の差が大きいほどベイズ因子の証拠が強い」と解釈できます。一方、AIC は事前分布を含まないため、ベイズ因子と厳密には対応しません。ベイズ因子は事前分布に依存する点に注意が必要です。

本章のまとめ

- 周辺尤度 = 事前予測分布で実データを評価した値。
- ベイズ因子 = 二つのモデルの周辺尤度の比。事前オッズを更新する倍率。
- ジェフリーズの基準で証拠の強さを解釈する。
- BIC はベイズ因子の近似。AIC は事前分布を含まない予測重視の指標。

練習問題

練習問題 8.1 例8.1 と同じ設定で、20回投げて表が16回出た場合のベイズ因子 BF_{10} を計算しなさい。

練習問題 8.2 ベイズ因子が事前分布に依存することの利点と注意点をそれぞれ述べなさい。

練習問題 8.3 ジェフリーズの基準を使って、 $BF = 25$ をどう解釈するか答えなさい。

練習問題 8.4 AIC と BIC の違いを、目的（予測 vs 説明）の観点から説明しなさい。

第9章 多腕バンディットと意思決定

学習目標

- 探索 (exploration) と活用 (exploitation) のトレードオフを理解する。
- Thompson sampling のアルゴリズムを理解し、実装の考え方を説明できる。
- UCB と ϵ -greedy の基本的な考え方を理解する。
- A/B テストとベイズ的判断の関係を理解する。

9.1 探索と活用のトレードオフ

「どのボタンがクリックされやすいか」「どの広告が効くか」など、複数の選択肢（アーム）から最良のものを選びたい状況を考えます。この問題は**多腕バンディット問題**と呼ばれます。

- 活用 (exploitation) : 今まで最良とわかっている選択肢を選ぶ。
- 探索 (exploration) : まだ不確実な選択肢も試して情報を集める。

活用ばかりだと「実は良かった」選択肢を永遠に見逃し、探索ばかりだと性能を捨てることになります。このジレンマを探索と活用のトレードオフと呼び、ベイズ統計は自然な解決策を与えます。

9.2 Thompson sampling

Thompson sampling は、ベイズ統計をそのまま使った多腕バンディット手法です。

1. 各アーム i の成功確率 θ_i に事後分布 $\text{Beta}(\alpha_i, \beta_i)$ を持たせる。
2. 各アームから事後分布のランダムなサンプル $\tilde{\theta}_i$ を引く。
3. サンプルが最大のアームを選択し、結果（成功/失敗）でそのアームの事後分布を更新する。

この単純な手続きが、不確実性が高いアームほど「偶然大きなサンプル」を引いて選ばれやすくなるため、探索と活用のバランスを自動的に取ります。理論的には regret（後悔）を最小化することが知られています。

Thompson sampling は現在、業界標準の手法です。たとえば配達プラットフォーム大手の DoorDash は、2025年12月に Thompson sampling ベースの多腕バンディットプラットフォームの詳細を公開しました。従来の A/B テスト（固定サンプルサイズ・固定トラフィック配分）による機会損失 (regret) を、事後分

布からのサンプリングによる動的配分で削減する狙いです。実務上は、対照群に対する効果量 (treatment effect) の事前分布を直接モデル化するなど、現実の課題への工夫が加えられています (DoorDash Engineering Blog, 2025-12-11)。

例 9.1 広告Aと広告Bのクリック率を比較します。事前分布は両方 $\text{Beta}(1, 1)$ 。広告Aを20回表示し5クリック、広告Bを10回表示し4クリックだった。

- Aの事後分布 $\text{Beta}(6, 16)$ 、事後平均 $6/22 \approx 0.273$
- Bの事後分布 $\text{Beta}(5, 7)$ 、事後平均 $5/12 \approx 0.417$

平均だけ見るとBが良さそうですが、Bは標本が少なく不確実性が大きいので、Thompson sampling は「Bが本当に良いかもしれない」可能性を探索に組み込みます。

9.3 UCB と ϵ -greedy

頻度論的なアプローチもあります。

- ϵ -greedy: 確率 ϵ でランダムに探索し、それ以外は今の最良を活用する。 ϵ はあらかじめ決める必要がある。
- UCB (Upper Confidence Bound) : 各アームの平均に不確実性の上界を加えた指標を最大化する。区間推定の「上端」を使うので、探索を自動的に行う。

UCB の指標は、アーム i の平均 $\hat{\theta}_i$ と、試行回数 n_i に依存する項 $c\sqrt{(\log n / n_i)}$ の和で表されることが多いです。試行回数が少ないアームほどこの項が大きく、探索されます。Thompson sampling との違いは、UCB が決定的な指標で選ぶのに対し、Thompson sampling は確率的に選ぶ点です。

9.4 A/B テストとベイズの判断

従来の A/B テストは「有意水準5%で B が A より良い」という判断を、仮説検定で行います。しかし：

- 検定は「打ち切りの時期」に依存しやすく、途中で何度も見ると誤った結論に陥る。
- 「B が A よりどれだけ良いか」の不確実性を直接示せない。

ベイズでは、クリック率の差 $\theta_B - \theta_A$ の事後分布を直接計算し、「 $\theta_B > \theta_A$ である確率」を報告できます。

例 9.2 例9.1 の設定で、 $\theta_B - \theta_A$ が正である事後確率を (数値計算で) 求めると約 0.80 になります。「BがAより良い確率が約80%」と報告でき、これは A/B テストの p 値より直感的です。

9.5 ベイズ最適化の考え方

多腕バンディットの考え方は、ハイパーパラメータ探索や実験計画にも発展します。ベイズ最適化では、未知の関数 $f(x)$ (たとえば学習率と精度の関係) をガウス過程でモデル化し、獲得関数 (expected improvement など) を最大化する x を逐次的に選びます。不確実性を明示的に扱う点で、多腕バンディットと共通の精神を持っています。

実務では、ハイパーパラメータ探索ライブラリ **Optuna** のガウス過程ベースのサンプラー (GPSampler) や、PyTorch エコシステムの **BoTorch** などに実装されており、機械学習モデルの調整に広く使われています。ガウス過程の予測は「平均 ± 不確実性」の形で与えられるため、探索（不確実性の大きい領域）と活用（期待値の高い領域）のバランスを取ることができます。

本章のまとめ

- 探索と活用のトレードオフは、不確実性を確率分布で持つベイズ統計が自然に解決する。
- Thompson sampling は事後分布からサンプルして選ぶだけで、探索と活用を両立する。
- ϵ -greedy や UCB は探索量を外部から制御する頻度論的手法。
- ベイズの A/B 判断は「差が正である確率」を直接報告できる。

練習問題

練習問題 9.1 Thompson sampling で、事後分布のサンプル値が最大のアームを選ぶことが、なぜ探索と活用を両立することになるのか説明しなさい。

練習問題 9.2 例9.1 の設定で、もしさらに広告Aを20回表示して8クリック増えたら、Aの事後分布はどうなるか求めなさい。

練習問題 9.3 ϵ -greedy と Thompson sampling の違いを、探索の「決まり方」の観点から比較しなさい。

練習問題 9.4 A/B テストで「途中で何度も有意性を確認する」ことがなぜ問題か、検定の反復と多重比較の観点から述べなさい。

第10章 MCMC入門と実践

学習目標

- 事後分布の解析計算が難しい場合に MCMC が使われる理由を理解する。
- マルコフ連鎖の基本概念を理解する。
- メトロポリス=ヘイスティングス法とギブスサンプリングのアルゴリズムを理解する。
- Python と PyMC での実践の流れを把握する。

10.1 なぜ MCMC が必要か

ここまでの章では、共役事前分布を使うことで事後分布を手計算してきました。しかし現実のモデルでは：

- 事前分布が共役でない（たとえば一様分布でも正規分布でもない複雑な形状）。
- パラメータが多次元で、周辺分布を求める積分が解析的に不可能。

このような場合、事後分布からのサンプルを数値的に発生させ、そのサンプルの平均や分位数を事後分布の要約として使います。この手法の代表が **MCMC**（マルコフ連鎖モンテカルロ法）です。

モンテカルロ法は乱数を使う数値計算全般を指し、マルコフ連鎖は「次に移る確率が現在の状態だけに依存する」確率過程です。MCMC は、マルコフ連鎖を使って事後分布からサンプルを得る手法です。

10.2 マルコフ連鎖

状態の列 $X_0, X_1, X_2, \dots$ があり、次に移る確率が現在の状態だけに依存する、つまり

$$P(X_{t+1} | X_t, X_{t-1}, \dots, X_0) = P(X_{t+1} | X_t)$$

が成り立つとき、これをマルコフ連鎖といいます。遷移確率が適切な条件を満たすと、十分に時間が経った後の状態の分布は、初期状態に関係なく定常分布と呼ばれる一定の分布に収束します。

MCMC のアイデアは、定常分布が求めたい事後分布になるように遷移規則を設計することです。設計どおりに回せば、連鎖の途中から得られるサンプルは事後分布に従うことになります。

10.3 メトロポリス＝ヘイスティングス法

最も基本的な MCMC アルゴリズムがメトロポリス＝ヘイスティングス (MH) 法です。

1. 初期値 θ^0 を決める。
2. $t = 0, 1, 2, \dots$ について：
3. 提案分布 $q(\theta^* | \theta^t)$ から候補 θ^* をサンプル。
4. 受容確率 $\alpha = \min(1, p(\theta^* | x) q(\theta^t | \theta^*) / (p(\theta^t | x) q(\theta^* | \theta^t)))$ を計算。
5. 確率 α で $\theta^{t+1} = \theta^*$ 、確率 $1 - \alpha$ で $\theta^{t+1} = \theta^t$ 。

ポイントは、事後分布の正規化定数を知らなくてよいことです。 $p(\theta | x) \propto p(x | \theta)p(\theta)$ の比だけを使うので、周辺尤度を計算する必要がありません。提案分布が対称 ($q(\theta^* | \theta^t) = q(\theta^t | \theta^*)$) なら、 $\alpha = \min(1, p(\theta^* | x) / p(\theta^t | x))$ と簡単になります (これをメトロポリス法と呼びます)。

例 10.1 平均未知・分散既知の正規モデル (第5章) を MH 法で解く例を考えます。事前分布 $N(\mu_0, \tau_0^2)$ 、データから事後分布は解析的に $N(\mu_1, \tau_1^2)$ と求められますが、あえて MH 法でサンプリングし、結果が一致することを確認できます。提案分布は現在の μ を中心とした $N(\mu^t, s^2)$ を使うのが一般的です。

10.4 ギブスサンプリング

パラメータが複数ある場合、ギブスサンプリングは各パラメータを「他のパラメータを固定した条件付き分布」から順番にサンプリングする方法です。正規-逆ガンマモデルでは、次のように交互に更新します。

1. σ^2 を固定して、条件付き分布 $p(\mu | \sigma^2, x)$ (正規分布) から μ をサンプル。
2. μ を固定して、条件付き分布 $p(\sigma^2 | \mu, x)$ (逆ガンマ分布) から σ^2 をサンプル。

これを繰り返すと、 (μ, σ^2) のサンプルが事後分布に収束します。ギブスサンプリングは MH 法の特別な場合とみなせ、条件付き分布が扱いやすい形になるモデルで非常に効率的です。

10.5 収束診断

MCMC サンプルの質を確認する必要があります。

- バーンイン (burn-in) : 初期のサンプルは初期値に依存するため捨てる。
- トレースプロット: サンプル列を描き、定常分布に収束しているか、ふらつき（探索範囲）を目視確認。
- R²統計量 (Gelman-Rubin) : 複数のチェーンを独立に走らせ、チェーン間の分散とチェーン内の分散を比較。R²が 1.1 未満なら収束とみなすのが一般的 (Stan などの実装では、分割・ランク正規化された R²が使われる)。
- 自己相関: 隣り合うサンプルは相関するため、間引き (thinning) やサンプル数の確保が必要。有効サンプル数 (ESS) で評価する。

10.6 Python / PyMC での実践

Python では PyMC (旧 PyMC3) が代表的です。現在のメジャーバージョンは PyMC 6 (2026年5月リリース) で、デフォルトのサンプラーに高速な **nutpie** (NUTS 実装) が採用されています。ベルヌーイ・ベータモデルを PyMC で書くと、次のような流れになります。

```
import pymc as pm
import numpy as np

data = np.array([1, 1, 1, 0, 1, 1, 0, 1, 1, 0]) # 表=1

with pm.Model():
    theta = pm.Beta("theta", alpha=1, beta=1)          # 事前分布
    obs = pm.Bernoulli("obs", p=theta, observed=data)  # 尤度
    trace = pm.sample(2000, tune=1000, chains=4)       # MCMC

pm.summary(trace) # 事後平均・HPD区間など
```

手計算で求めた $\text{Beta}(\alpha + k, \beta + n - k)$ の結果 (この例では表6回・裏4回で $\text{Beta}(7, 5)$ 、事後平均 $7/12 \approx 0.583$) と、PyMC の結果がほぼ一致することを確認できます。PyMC は内部で NUTS (No-U-Turn Sampler) という効率的なハミルトニアン MCMC を自動選択するため、ユーザーはモデル定義に集中できます。

なお、主要な確率的プログラミング言語 (PPL) はいずれも NUTS をデフォルトのサンプラーとして採用しています。PyMC 6 の nutpie、JAX ベースの NumPyro、そして統計モデリング言語 Stan (CmdStan 2.39、2026年5月リリース) がその代表例です。この章で学んだ MCMC の概念は、どのライブラリでも共通の土台になります。

10.7 総まとめ

本書で学んだことを振り返ります。

- 第1章～第2章: 確率の基礎とベイズの定理。データで信念を更新する。
- 第3章～第6章: 事前分布・尤度・事後分布の基本。共役事前分布でベータ・二項、正規、ポアソン・ガンマモデルを手計算。
- 第7章: 事後平均・MAP・信用区間。頻度論との解釈の違い。
- 第8章: ベイズ因子によるモデル選択。
- 第9章: 多腕バンディット。ベイズ推論の意思決定への応用。
- 第10章: MCMC による数値的な事後分布の獲得。

ベイズ統計の本質は、「不確実性を確率分布として扱い、データで逐次的に更新する」という一貫した枠組みにあります。共役事前分布での手計算 → MCMC による一般のモデルへの拡張 → 実データへの適用、という流れを自分の手で追ってみてください。

本章のまとめ

- 解析が不可能な事後分布は MCMC でサンプリングして要約する。
- マルコフ連鎖の定常分布を事後分布にするのが MCMC の設計思想。
- MH 法は提案分布から候補を出し、確率 α で受容する。正規化定数は不要。
- ギブスサンプリングは条件付き分布から順番にサンプルする。
- 収束はトレース・R・ESS で診断する。PyMC で簡単に実行できる。

練習問題

練習問題 10.1 MH 法が事後分布の正規化定数を計算しなくてよい理由を、受容確率の式に言及して説明しなさい。

練習問題 10.2 マルコフ連鎖の「マルコフ性」とは何か、式を用いて説明しなさい。

練習問題 10.3 ギブスサンプリングと MH 法の間係を説明しなさい。

練習問題 10.4 R 統計量が大きいとき（たとえば1.3）に何が疑われるか、またその対処法を述べなさい。

付録A 練習問題の解答

第1章

練習問題 1.1 赤玉を引いた後、袋には赤玉3個、白玉6個の計9個が残る。よって条件付き確率は $6/9 = 2/3$ 。

練習問題 1.2 全確率の定理とベイズの定理を使う。 $P(\text{陽性}) = 0.95 \times 0.01 + 0.10 \times 0.99 = 0.0095 + 0.099 = 0.1085$ 。 $P(\text{病気} | \text{陽性}) = 0.0095 / 0.1085 \approx 0.0876$ 。約8.8%。第2章の本文で詳しく扱う。

練習問題 1.3 先手がBさんである事象を B、Aさんが勝つ事象を W とする。 $P(W) = P(W|B)P(B) + P(W|B^c)P(B^c) = (1/2)(1/2) + (3/4)(1/2) = 1/4 + 3/8 = 5/8$ 。

練習問題 1.4 独立である。2回のさいころは独立だから $P(1回目が偶数 \text{ かつ } 2回目が6) = P(1回目が偶数)P(2回目が6) = (1/2)(1/6) = 1/12$ が成り立つ。

第2章

練習問題 2.1 $P(\text{不良}|\text{陽性判定}) = (0.98 \times 0.05) / (0.98 \times 0.05 + 0.04 \times 0.95) = 0.049 / (0.049 + 0.038) = 0.049 / 0.087 \approx 0.563$ 。約56%。

練習問題 2.2 データは5回中表3回。 $P(\theta = 0.6 | \text{データ}) = [C(5,3)0.6^3 0.4^2 \times 1/2] / [C(5,3)0.6^3 0.4^2 \times 1/2 + C(5,3)0.4^3 0.6^2 \times 1/2]$ 。 $C(5,3)$ と $1/2$ はキャンセルされ、 $= (0.6^3 0.4^2) / (0.6^3 0.4^2 + 0.4^3 0.6^2) = (0.03456) / (0.03456 + 0.02304) = 0.03456 / 0.0576 = 0.6$ 。

練習問題 2.3 新しいデータは5回中表4回。全データは10回中表7回。 $P(\theta = 0.6 | \text{全データ}) = (0.6^7 0.4^3) / (0.6^7 0.4^3 + 0.4^7 0.6^3) = 0.6^4 / (0.6^4 + 0.4^4) = 0.1296 / (0.1296 + 0.0256) = 0.1296 / 0.1552 \approx 0.835$ 。約83.5%。

練習問題 2.4 1回目: $P \approx 0.0876$ 。2回目: $P \approx (0.95 \times 0.0876) / (0.95 \times 0.0876 + 0.10 \times 0.9124) \approx 0.477$ 。3回目: $P \approx (0.95 \times 0.477) / (0.95 \times 0.477 + 0.10 \times 0.523) = 0.453 / 0.505 \approx 0.897$ 。約90%。

第3章

練習問題 3.1 表が3回、裏が1回。 $p(\theta | x) \propto \theta^3 (1 - \theta) \times 1 = \theta^3 (1 - \theta)$ 。

練習問題 3.2 $B(4,2) = \Gamma(4) \Gamma(2) / \Gamma(6) = (3! \times 1!) / 5! = 6 / 120 = 1/20$ 。よって $p(\theta | x) = 20 \theta^3 (1 - \theta)$ 。
積分 $\int_0^1 20 \theta^3 (1 - \theta) d\theta = 20 \times (1/20) = 1$ を確認できる。

練習問題 3.3 Beta(10,10)を事前分布に使うと、事後分布は Beta(10+3, 10+1) = Beta(13, 11)。一様分布 (Beta(1,1))の場合は Beta(4,2)。Beta(13,11)は中心0.5付近に強く集まった分布で、データ(0.75)より0.5側に引っ張られる。事前分布が強いほど事後平均はデータから遠ざかる。

練習問題 3.4 最尤推定は尤度 $L(\theta)$ だけを最大化し、事前情報を使わない。ベイズ推定は事前分布 $p(\theta)$ と尤度の積 $p(\theta | x) \propto p(x | \theta) p(\theta)$ の事後分布から推定する。事前分布が「正則化」の働きをし、データが少ないときの過学習を防ぐ。

第4章

練習問題 4.1 事後分布 Beta(3+12, 3+8) = Beta(15, 11)。事後平均 = $15 / 26 \approx 0.577$ 。MAP = $(15 - 1) / (15 + 11 - 2) = 14 / 24 \approx 0.583$ 。

練習問題 4.2 一様事前分布 (Beta(1,1))では、事後分布は Beta(1+k, 1+n-k)なので、事後平均 = $(1+k) / (n+2)$ 。 k/n とのずれは、 $(1+k) / (n+2) - k/n = (n - 2k) / (n(n+2))$ 。つまり $k < n/2$ (表の割合が1/2未満)なら k/n より大きく、 $k > n/2$ なら k/n より小さくなる。すなわち事後平均は常に0.5側へ引っ張られる。たとえば $n=2, k=1$ では事後平均 = $2/4 = 0.5 = k/n$ 。 $n=10, k=8$ では事後平均 = $9/12 = 0.75 < k/n = 0.8$ 。少ないデータでは事前の一様分布の影響で0.5側に寄る。

練習問題 4.3 事前分布 Beta(2,2)、データ 表8・裏2。事後分布 Beta(10, 4)。次に表が出る確率 = 事後平均 = $10 / 14 \approx 0.714$ 。

練習問題 4.4 Beta(10, 2): 期待値 = $10 / 12 \approx 0.833$ 。分散 = $(10 \times 2) / (12^2 \times 13) = 20 / 1872 \approx 0.0107$ 。最頻値 = $(10 - 1) / (10 + 2 - 2) = 9 / 10 = 0.9$ 。

第5章

練習問題 5.1 $n=20, \bar{x}=10.5, \sigma^2=4$, 事前 $N(10, 9)$ 。データ精度 $n/\sigma^2 = 20/4 = 5$ 、事前精度 $1/9$ 。 $\tau_1^2 = 1/(1/9 + 5) = 1/5.111 \approx 0.1957$ 。 $\mu_1 = 0.1957 \times (10/9 + 5 \times 10.5) = 0.1957 \times (1.111 + 52.5) = 0.1957 \times 53.611 \approx 10.49$ 。 n が増えると事後平均は標本平均 10.5 に近づき、事後分散は小さくなる。

練習問題 5.2 $1/\tau_0^2 \approx 0$ なので、 $\tau_1^2 \approx \sigma^2/n$ 、 $\mu_1 \approx (n\bar{x}/\sigma^2)/(n/\sigma^2) = \bar{x}$ 。つまり事前の影響を無視した標本平均になり、最尤推定と一致する。

練習問題 5.3 予測分布の分散 $\sigma^2 + \tau_1^2$ には、データ自身のばらつき σ^2 に加えて μ の不確実性 τ_1^2 が加わるため。 μ を「点」で推定するのではなく、その不確実性をそのまま次のデータの予測に反映するから。

練習問題 5.4 分散 σ^2 自体が不確実（分布を持つ）ため、データを標準化するときのスケールが一定でなく、裾が重くなる。つまり極端な値が正規分布より起こりやすい。自由度 $\nu = 2a_1$ が大きくなると分散の不確実性が減り、 t 分布は正規分布に近づく。

第6章

練習問題 6.1 $\text{Gamma}(5, 2)$: 期待値 $= 5/2 = 2.5$ 。分散 $= 5/4 = 1.25$ 。

練習問題 6.2 事後分布 $\text{Gamma}(1+18, 1+12) = \text{Gamma}(19, 13)$ 。事後平均 $= 19/13 \approx 1.46$ 回/月。

練習問題 6.3 $E[X] = \sum_{k=0}^{\infty} k \lambda^k e^{-\lambda} / k! = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \lambda^{k-1} / (k-1)! = \lambda e^{-\lambda} e^{\lambda} = \lambda$ 。 $E[X^2] = E[X(X-1)] + E[X] = \lambda^2 + \lambda$ ($E[X(X-1)] = \lambda^2$ は同様に計算)。よって $\text{Var}(X) = E[X^2] - (E[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$ 。

練習問題 6.4 前の事後分布 $\text{Gamma}(19, 13)$ を新しい事前分布として、さらに6ヶ月・8回のデータを足す。 $\text{Gamma}(19+8, 13+6) = \text{Gamma}(27, 19)$ 。事後平均 $= 27/19 \approx 1.42$ 回/月。

第7章

練習問題 7.1 $\text{Beta}(30, 20)$: 事後平均 $= 30/50 = 0.6$ 。MAP $= (30-1)/(30+20-2) = 29/48 \approx 0.604$ 。

練習問題 7.2 信用区間は「 θ （確率変数）が区間に入る確率が95%」。信頼区間は「 θ （固定値）を中心に、手順を何度も繰り返せば95%の割合で区間が θ を含む」という手順の性質。ベイズでは確率変数が θ 、頻度論では確率変数が区間（の端点）。

練習問題 7.3 $\text{Beta}(9, 3)$ の2.5%分位数と97.5%分位数。事後分布の確率質量の下側2.5%と上側2.5%を切り取った残りの区間で、「 θ がこの区間に入る確率が95%」を意味する。

練習問題 7.4 等裾区間は二峰の谷を含み、確率質量を無駄に切り落とす可能性がある。HPD区間は密度の高い領域を選ぶので、二峰分布では両峰を囲む2つの区間に分解されることがあり、より「もっともらしい領域」を表す。HPDが適切。

第8章

練習問題 8.1 $M_0: p(x|M_0) = C(20, 16)(1/2)^{20} = 4845/1048576 \approx 0.00462$ 。 $M_1: p(x|M_1) = C(20, 16) \times B(17, 5) = 4845 \times (16! \times 4! / 21!) = 4845 \times (24 / (17 \times 18 \times 19 \times 20 \times 21)) = 4845 \times 24 / 2441880 = 4845 / 101745 \approx 0.04762$ 。 $\text{BF}_{10} = 0.04762 / 0.00462 \approx 10.3$ 。ジェフリーズの基準で「強い証拠」。

練習問題 8.2 利点: 事前情報を明示的にモデル選択に反映でき、試行回数が少ないときに過度な結論を避ける (例8.1)。注意点: 無情報事前分布の選び方で周辺尤度が変わり、ベイズ因子が変わる。特に無情報事前分布は「分散が大きすぎると周辺尤度が変わる」ため、事前分布の選択に敏感。

練習問題 8.3 $BF = 25$ は 10~30 の範囲で「強い証拠」。 M_1 が M_2 の25倍のデータ支持を得ている。

練習問題 8.4 AIC は予測性能を重視し、サンプルサイズのペナルティを含まない (パラメータ数 $\times 2$)。

BIC は説明・モデル選択を重視し、 n が大きいほど強いペナルティ (パラメータ数 $\times \log n$) を課す。 n が大きいとき BIC の差はベイズ因子の近似に対応する。

第9章

練習問題 9.1 事後分布のサンプルは「その時点の信念」を確率的に表す。試行回数が少ないアームは分散が大きく、偶然大きなサンプルを引く確率が高い。その結果、不確実なアームが選ばれる機会 (探索) が生まれる。一方で事後分布が平均的に高いアームは頻繁に選ばれる (活用)。よって両者を自動的に両立する。

練習問題 9.2 広告A: 追加で20回中8クリック。累計で40回中13クリック。事後分布 $\text{Beta}(1+13, 1+27) = \text{Beta}(14, 28)$ 。事後平均 = $14/42 \approx 0.333$ 。

練習問題 9.3 ϵ -greedy は「確率 ϵ で一様にランダムに探索」と、外部から固定した ϵ で探索量を制御する。Thompson sampling は事後分布の不確実性の大きさに応じて探索量が自動的に変化する。 ϵ の調整が不要で、試行が進むにつれて探索量が自然に減少する。

練習問題 9.4 検定を繰り返し行くと「有意」になる確率が増え、多重比較の問題になる。たとえば有意水準5%で何度も検定すれば、全体の誤検出率が上昇する。ベイズの事後確率は逐次更新してもこのような多重比較の問題が起きず、途中で判断しても解釈が安定する。

第10章

練習問題 10.1 受容確率 $\alpha = \min(1, p(\theta^*|x)q(\theta^*|\theta)/(p(\theta|x)q(\theta^*|\theta)))$ は、分子と分母に同じ正規化定数 $Z = \int p(x|\theta)p(\theta)d\theta$ が掛かっているため、キャンセルされる。よって $p(\theta|x) \propto p(x|\theta)p(\theta)$ の比例関係だけで計算でき、 Z を知る必要がない。

練習問題 10.2 マルコフ性とは「次の状態の分布が現在の状態のみに依存し、過去の履歴には依存しない」性質。 $P(X_{t+1} | X_t, X_{t-1}, \dots, X_0) = P(X_{t+1} | X_t)$ 。

練習問題 10.3 ギブスサンプリングは、各パラメータをその条件付き分布からサンプリングする MH 法の特別な場合。受容確率が常に1になる (条件付き分布から直接サンプルするため常に受容される) 点で、MH 法より効率的。

練習問題 10.4 R が1に近くない (たとえば1.3) のは、複数のチェーンが異なる領域に留まっていて、まだ定常分布に収束していないことを示す。対処法: バーンインを長く取る、チェーン数を増やす、パラメータの初期値を分散させる、モデルのパラメータ化を改善する (再パラメータ化)。

付録B 用語集

50音順 (アルファベット部分は末尾) です。

- かつよう (活用): 今まで最良とわかっている選択肢を選ぶこと。探索とトレードオフにある。

- かくりつ（確率）：事象の起こりやすさを0から1の数値で表したもの。頻度論では相対頻度、ベイズ統計では信念の度合いと解釈される。
- がんまかんすう（ガンマ関数）： $\Gamma(a) = \int_0^\infty t^{a-1} e^{-t} dt$ 。ベータ関数やガンマ分布の正規化定数に現れる。
- がんまぶんぷ（ガンマ分布）：正のパラメータ a, b をもつ連続分布。ポアソン分布のパラメータ λ の共役事前分布。期待値 a/b 。
- ぎやくがんまぶんぷ（逆ガンマ分布）：正規分布の分散 σ^2 の共役事前分布。期待値 $b/(a-1)$ ($a>1$)。
- ぎぶすさんぷりんぐ（ギブスサンプリング）：各パラメータを、他のパラメータを固定した条件付き分布から順番にサンプリングするMCMC法。MH法の特別な場合。
- きょうやくこうしん（共役更新）：共役事前分布を使い、パラメータの足し算だけで事後分布を求めること。
- きょうやくじぜんぶんぷ（共役事前分布）：事後分布が事前分布と同じ分布族になる事前分布。計算を大幅に簡単にする。
- しゅうへんゆうど（周辺尤度）： $\int p(x|\theta)p(\theta)d\theta$ 。事後分布の正規化定数であり、モデル選択やベイズ因子に使う。
- じゅうよう（受容）：MH法で提案された候補を受け入れること。受容確率 α で判定する。
- しんようくかん（信用区間）：事後分布から作る区間。「パラメータがこの区間に入る確率95%」と直接解釈できる。
- じごよそくぶんぷ（事後予測分布）：パラメータの不確実性を積分で消した、新しいデータの分布。予測分布の分散はパラメータの不確実性ぶん広がる。
- じごぶんぷ（事後分布）：データを見た後のパラメータの分布。事前分布 $\times$ 尤度を正規化して1になるよう調整したもの。
- しんらいくかん（信頼区間）：頻度論の区間推定。「手順を繰り返すと95%の割合で真値を含む」という意味。
- じぜんよそくぶんぷ（事前予測分布）：データを見る前に、モデルと事前分布で予測する新しいデータの分布。 $\int p(x_{\text{new}}|\theta)p(\theta)d\theta$ 。
- じぜんぶんぷ（事前分布）：データを見る前のパラメータの分布。無情報・弱情報などがある。
- しんねん（信念）：ベイズ統計で「確率」が表す主観的な不確実性の度合い。
- じょうけんつきかくりつ（条件付き確率）： $P(A|B) = P(A \cap B)/P(B)$ 。Bに絞った世界でのAの割合。
- ぜんかくりつていり（全確率の定理）：分割 $B_1, \dots, B_n$ に対して $P(A) = \sum P(A|B_i)P(B_i)$ 。
- たんさく（探索）：まだ不確実な選択肢を試して情報を集めること。活用とトレードオフにある。
- たわんばんでいっと（多腕バンディット）：複数の選択肢から最良を探す問題。探索と活用のトレードオフを扱う。
- ちくじこうしん（逐次更新）：前の事後分布を次の事前分布にして、データのたびに更新すること。ベイズ更新ともいう。
- てんすいてい（点推定）：パラメータを1つの値で推定すること。事後平均・MAP・事後中央値。
- どくりつ（独立）： $P(A \cap B) = P(A)P(B)$ 。Bを知ってもAの確率が変わらないこと。排反とは別概念。
- はいはん（排反）：二つの事象が同時に起こらないこと。 $A \cap B = \emptyset$ 。

- ひょうほん（標本）：母集団から選んだ一部のデータ。
- ぶんかつ（分割）：標本空間を互いに排反な部分で覆うこと。全確率の定理の前提。
- ぶんさん（分散）：分布の広がり。 $\text{Var}(X) = E[(X - E[X])^2]$ 。
- ベータぶんぷ（ベータ分布）： $[0,1]$ 上の連続分布。ベルヌーイ・二項モデルの共役事前分布。期待値 $\alpha/(\alpha + \beta)$ 。
- ぼすう（母数）：パラメータ。分布を特徴づける未知の量。
- まるこふれんさ（マルコフ連鎖）：次の状態が現在の状態のみに依存する確率過程。
- めとろぼりすへいすていんぐすほう（メトロポリス＝ヘイスティングス法）：MCMCの基本アルゴリズム。提案分布から候補を出し、受容確率 α で受容する。
- もんてかるろほう（モンテカルロ法）：乱数を使う数値計算の総称。
- ゆうど（尤度）：パラメータ θ の関数として見たデータの確率。 $L(\theta) = f(x|\theta)$ 。
- ゆうどかんすう（尤度関数）：尤度を参照。
- よそく（予測）：事後予測分布を使った新しいデータの予測。
- AIC: 赤池情報量規準。 $-2\log L + 2k$ 。予測性能を重視したモデル選択指標。
- BIC: ベイズ情報量規準。 $-2\log L + k \log n$ 。ベイズ因子の近似。
- BF（ベイズ因子）：二つのモデルの周辺尤度の比。証拠の強さを表す。
- ESS: 有効サンプル数。MCMCサンプルで自己相関を考慮した独立サンプル数の目安。
- HPD区間: 事後密度が高い領域から集めた信用区間。最短になる。
- MCMC: マルコフ連鎖モンテカルロ法。事後分布からサンプルを発生させる数値法。
- MAP推定: 事後分布の最頻値を推定値とする方法。
- MH法: メトロポリス＝ヘイスティングス法の略。
- NIG（正規－逆ガンマ分布）：平均と分散が両方未知の正規モデルの共役事前分布。
- PPC: 事後予測チェック。モデルの適合性を調べる。
- $\hat{R}$: Gelman-Rubin の収束診断統計量。1.1未満なら収束とみなす。
- Thompson sampling: 事後分布からのサンプルで選択肢を選ぶ多腕バンディット手法。
- UCB: 不確実性の上界（Upper Confidence Bound）を最大化する多腕バンディット手法。
- ϵ -greedy: 確率 ϵ でランダムに探索する多腕バンディット手法。

※用語集には本書で実際に使われた主要な用語のみを収載しています。

付録C 記号表

記号	意味
Ω	標本空間
$P(A)$	事象 A の確率
$P(A B)$	B のもとでの A の条件付き確率
$P(A \cap B)$	A と B の積事象
B_i	分割（原因）の i 番目
θ	パラメータ（未知の母数）

記号	意味
$x_1, \dots, x_n$	データ（標本）
$\bar{x}$	標本平均
n	標本サイズ（試行回数）
k	成功回数（表の回数）
$L(\theta)$	尤度関数
$p(\theta)$	事前分布（密度）
$p(\theta x)$	事後分布（密度）
$p(x \theta)$	尤度（密度）
$p(x)$	周辺尤度
$\propto$	比例する
$E[X]$	期待値
$\text{Var}(X)$	分散
$\Gamma(a)$	ガンマ関数
$B(\alpha, \beta)$	ベータ関数
$C(n, k)$	二項係数 $n!/(k!(n-k)!)$
$N(\mu, \sigma^2)$	正規分布（平均 μ 、分散 σ^2 ）
$\text{Beta}(\alpha, \beta)$	ベータ分布
$\text{Gamma}(a, b)$	ガンマ分布
$\text{Inv-Gamma}(a, b)$	逆ガンマ分布
$\text{Poisson}(\lambda)$	ポアソン分布（平均 λ ）
$\text{NIG}(\mu_0, \kappa_0, a_0, b_0)$	正規-逆ガンマ分布
μ_0, τ_0^2	事前の平均と分散
μ_1, τ_1^2	事後の平均と分散
α', β'	事後のベータ分布のパラメータ
BF_{12}	モデル1対2のベイズ因子
θ^i, θ^*	MCMC の現在値と候補値
$q(\theta^* \theta^i)$	提案分布
α	MH 法の受容確率
ε	ε -greedy の探索率
n_i	アーム i の試行回数
x_{new}	新しい（予測する）データ

記号	意味
S	標本偏差の2乗和 $\sum (x_i - \bar{x})^2$

資格対応（統計検定）

本書の内容は、日本統計学会認定の統計検定のうち、以下の級の出題範囲に対応しています。

資格名	主催・認定	実際の合格基準	本書での取得相当目安
統計検定2級	一般財団法人統計質保証推進協会（日本統計学会認定）	100点満点中 60点以上	練習問題 1～4章（確率・ベイズの定理・確率分布）の正解率 70%以上
統計検定準1級	同上	100点満点中 60点以上	練習問題 全章（特に5～10章の事前分布・事後分布・モデル選択・MCMC）の正解率 70%以上
統計検定1級 （統計数理）	同上	非公表（筆記・論述）	全章の内容に加え、発展的な演習と証明の練習が必要

- 正解率 90%以上: 合格十分レベル（模擬試験合格相当）
- 正解率 70～89%: 合格レベル（受験可能・合格圏内）
- 正解率 50～69%: 基礎習得レベル（要復習）
- 正解率 50%未満: 未習得（章の復習が必要）

対応の説明

- 統計検定2級の出題範囲には「確率（統計的推測の基礎となる確率、ベイズの定理）」と「確率分布（各種の確率分布とその平均・分散）」が含まれます。本書の第1章（確率の基礎）、第2章（ベイズの定理）、第4章（ベルヌーイ・二項分布）、第6章（ポアソン分布）が直接対応します。
- 統計検定準1級の出題範囲には「ベイズ法」「モデル選択」が明記されており、本書の第3章～第8章（事前分布・事後分布・信用区間・ベイズ因子）が対応します。準1級の出題範囲表は2027年1月1日から改訂され、「事前分布、事後分布、MHアルゴリズム、MCMC法、ギブスサンプリング、階層ベイズモデル」とベイズ法の内容が明確化されています（本書の第10章が対応）。なお、同改訂では「統計的因果推論」が新たに出版範囲に追加されます。
- 1級は論述式で、MCMC を含む数理的厳密性が求められるため、本書（第10章）を足がかりにさらに数理的訓練が必要です。

※合格基準・出題範囲は統計検定公式サイト（<https://www.toukei-kentei.jp/>）の公開情報（2027年1月1日適用の準1級出題範囲表を含む）に基づきます。試験方式は CBT 方式（準1級～4級）です。合格率は公式には非公表です。